Transfer Learning untuk Klasifikasi Citra dengan Data Terbatas

Kenneth Howen — 2802504346 — Repositori: https://github.com/Kyurein/Advanced-CNNs-and-TransferLearning

1. Latar Belakang

Batch Normalization (Slide 6–8) dan residual connection (Slide 10–12) memungkinkan CNN dalam dilatih secara stabil, sedangkan transfer learning (Slide 14–18) memungkinkan representasi ImageNet dimanfaatkan pada dataset kecil. Studi ini menguji pertanyaan dari Slide 15–16: kapan cukup membekukan backbone (feature extraction) dan kapan fine-tuning diperlukan, pada data berlabel terbatas dan anggaran komputasi minimal.

2. Metodologi

Dataset Oxford-IIIT Pet (Parkhi et al., 2012) diambil 10 kelas: Abyssinian, Bengal, Birman, Bombay, Persian (kucing) serta Beagle, Boxer, Pug, Samoyed, Shiba Inu (anjing). Split resmi digabung lalu dibagi ulang secara stratified 70/15/15 (seed 42) menjadi 1.386/297/298 citra tanpa irisan. Protokol dan kondisi dirangkum pada Tabel 1. Pada layer yang dibekukan, BatchNorm dipaksa ke mode eval() agar running statistics ImageNet tidak berubah. Dua kali Run all menghasilkan metrik identik; yang berbeda hanya durasi.

Komponen	Pengaturan
Model & protokol	ResNet-18 (IMAGENET1K_V1), input 224×224 + normalisasi ImageNet, batch 32, AdamW (weight decay 1e-2), CrossEntropyLoss, early stopping pada validation loss (patience 4), seed 42
Augmentasi (train saja)	RandomResizedCrop(224, scale 0,8–1,0), HorizontalFlip, Rotation 15°, ColorJitter (brightness/contrast 0,2); val/test deterministik
Kondisi	B1: weights=None, semua parameter, LR 1e-3. B2: backbone dibekukan, fc → Linear(512, 10), LR 1e-3. B3: layer4 + fc dibuka, LR 1e-4/1e-3. B4: konfigurasi B3 dengan vs tanpa augmentasi (Resize/CenterCrop + normalisasi)
Lingkungan	Google Colab Tesla T4, Python 3.13.15, torch 2.11.0+cu130, torchvision 0.26.0+cu130, scikit-learn 1.6.1, mixed precision float16

Tabel 1. Protokol dan matriks kondisi eksperimen.

3. Bagian A — Analisis Konseptual

A1. Efek Regularisasi Batch Normalization (Slide 6–8)

Pada Batch Normalization (BN), setiap aktivasi dinormalisasi menggunakan rata-rata mini-batch (μ_B) dan variansnya (σ^2_B), bukan statistik seluruh data. Karena isi mini-batch berubah, kedua estimasi ikut berubah; akibatnya, sampel yang sama dapat memperoleh nilai aktivasi berbeda bergantung pada sampel lain yang kebetulan berada dalam batch. Variasi ini bertindak sebagai noise stokastik dan dapat memberi efek regularisasi (Ioffe & Szegedy, 2015; Slide 6–8). Namun, BN tidak selalu menggantikan Dropout. Pada batch kecil, estimasi μ dan σ^2 lebih tidak stabil. Selain itu, saat training BN memakai statistik batch, sedangkan saat evaluasi umumnya memakai running statistics. Jika distribusi saat inferensi berbeda atau statistik running tidak representatif, terjadi mismatch. Maka efek regularisasi BN bergantung pada ukuran batch, cara mode train/eval dikelola, dan kesesuaian distribusi training dengan inferensi.

A2. Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)

Pada tumpukan layer biasa, untuk mempertahankan identitas keluaran harus belajar komposisi bobot dan aktivasi non-linear yang secara tepat menghasilkan $H(x)=x$. Makin dalam tumpukan, makin kompleks optimisasi dan makin banyak faktor turunan yang mengalikan gradien; jika besar turunannya sering lebih kecil dari satu, sinyal gradien dapat mengecil (vanishing gradient), memperlambat pembelajaran (Sesi 02). ResNet menulis $y=F(x)+x$, sehingga Jacobian-nya $\partial y/\partial x=\partial F(x)/\partial x+I$; untuk gradien balik, $\partial L/\partial x=(\partial F/\partial x)^T\partial L/\partial y+\partial L/\partial y$. Suku identitas meneruskan gradien secara langsung, sehingga gradien tidak hanya bergantung pada turunan cabang F. Jalur pintas ini memberi mekanisme dekat-identitas bahkan ketika cabang F belum terlatih dengan baik. Ini membantu optimisasi jaringan dalam dan mengurangi degradasi (He et al., 2016; Slide 10–12), walau tidak menjamin hilangnya vanishing gradient sepenuhnya.

A3. Feature Extraction vs. Fine-Tuning (Slide 14–16)

Feature extraction membekukan backbone ImageNet dan hanya melatih kepala klasifikasi; fine-tuning membuka sebagian backbone agar fitur dapat beradaptasi ke domain target. Pertama, biaya optimisasi: B2 hanya memiliki 5.130 parameter trainable, sedangkan B3 8.398.858 (sekitar 1.637 kali lebih banyak). Kedua, waktu: B2 total 119,5 s/17 epoch ≈7,0 s/epoch; B3 43,5 s/6 epoch ≈7,3 s/epoch. Jadi rasio parameter tidak menjadi rasio waktu per epoch, karena kedua model tetap menjalankan forward pass backbone dan waktu juga dipengaruhi data loading serta penghentian dini. Ketiga, hasil: akurasi uji B2 0,9698 dan B3 0,9664, hampir

sama. Keempat, risiko/stabilitas: B2 lebih sedikit bobot berubah, sedangkan B3 lebih fleksibel tetapi berisiko merusak fitur pralatih. Untuk dataset kecil dan domain serupa ImageNet, mulai dari B2; buka layer akhir bila validasi menunjukkan kebutuhan adaptasi (Slide 14–16; Yosinski et al., 2014).

A4. Kaidah Penerapan Data Augmentation (Slide 20–22)

Augmentasi acak sebaiknya hanya dipakai pada data train. Jika diterapkan juga pada validation/test, setiap evaluasi dapat melihat versi gambar berbeda, sehingga metrik menjadi berisik dan tidak sepenuhnya dapat dibandingkan antar-epoch maupun antar-model. Transformasi acak juga dapat mengubah distribusi evaluasi dari gambar alami yang menjadi target penggunaan; praktik yang lebih tepat ialah validasi/test deterministik dan identik, sementara augmentasi meningkatkan variasi efektif data latih (Shorten & Khoshgoftaar, 2019; Slide 20–22). Tidak semua transformasi sesuai. Misalnya, RandomResizedCrop yang terlalu agresif hingga hanya menyisakan sebagian kecil bulu atau latar dapat menghilangkan wajah, bentuk moncong, atau pola bulu yang membedakan ras. Label asli tetap dipertahankan padahal bukti visual tidak lagi cukup untuk mengenalinya, sehingga pasangan gambar-label menjadi ambigu.

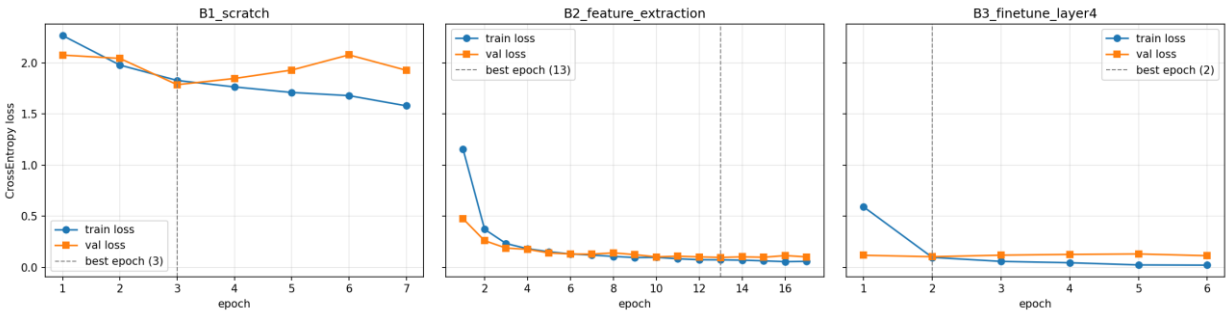
A5. Mitigasi Catastrophic Forgetting (Slide 28–29)

Catastrophic forgetting terjadi ketika pembaruan saat menyesuaikan model ke dataset target terlalu besar sehingga fitur pralatih yang berguna untuk tugas sebelumnya berubah atau hilang. Pada transfer ImageNet, layer awal sering mewakili tepi dan tekstur umum, sedangkan layer akhir cenderung lebih spesifik pada kelas sumber; perubahan agresif dapat menurunkan kemampuan representasi awal (Yosinski et al., 2014). Strategi pertama adalah membekukan layer awal dan membuka backbone secara bertahap, sehingga hanya fitur yang perlu beradaptasi yang diperbarui. Strategi kedua adalah memakai learning rate kecil pada backbone pralatih, memantau validation loss dengan early stopping, dan menyimpan checkpoint terbaik; secara teoretis, langkah kecil membatasi perpindahan bobot dari solusi pralatih. B3 menggunakan differential LR 1e-4 untuk layer4 dan 1e-3 untuk fc: kepala baru belajar cepat, sementara backbone berubah sepuluh kali lebih lambat. Ini mengurangi risiko, tetapi tidak menghilangkan forgetting sepenuhnya (Slide 28–29; Kirkpatrick et al., 2017).

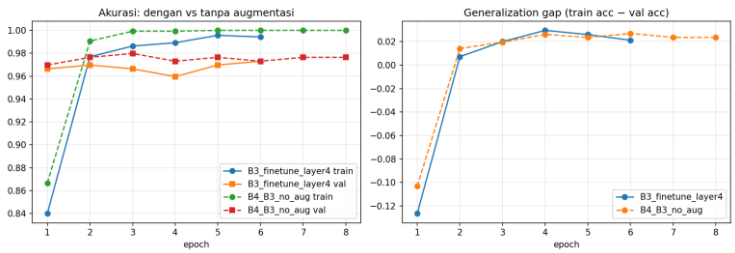
4. Hasil (C1)

Kode	Strategi	Trainable params	Learning rate	Best / total epoch	Waktu (s)	Val acc	Test acc	Test macro-F1
B1	From scratch	11.181.642	1e-3 (semua)	3 / 7	52,8	0,3502	0,3255	0,3204
B2	Feature extraction	5.130	1e-3 (fc)	13 / 17	119,5	0,9764	0,9698	0,9703
B3	Fine-tune layer4 (+aug)	8.398.858	1e-4 layer4; 1e-3 fc	2 / 6	43,5	0,9697	0,9664	0,9667
B4	B3 tanpa augmentasi	8.398.858	1e-4 layer4; 1e-3 fc	4 / 8	23,1	0,9731	0,9765	0,9767
B5	MobileNetV3-Small (bonus)	—	—	tidak dijalankan	—	—	—	—

Tabel 2. Konsolidasi hasil (sumber: outputs/summary.csv; test set 298 citra, 1 citra ≈ 0,34 poin persen).



Gambar 1. Training vs validation loss B1, B2, B3; garis putus-putus = epoch terbaik.



Gambar 2. Kontrol augmentasi (B4): akurasi train/val dan generalization gap per epoch.

5. Pembahasan Komparatif (C2)

5.1 From scratch (B1) vs transfer learning (B2, B3)

Performa B1 menunjukkan underfitting atau kegagalan konvergensi lebih dominan daripada overfitting klasik: akurasi train terakhir hanya 0,4452 dan validasi 0,3502, keduanya jauh di bawah B2/B3 yang melampaui 0,96 sejak epoch 1–2. B1 berhenti setelah 7 epoch dengan epoch terbaik ke-3, sehingga baseline from-scratch mungkin belum memperoleh pelatihan atau penyetelan yang cukup; hasil ini tidak membuktikan bahwa training from scratch selalu buruk. Residual connection membantu aliran gradien pada jaringan dalam (Slide 10–12), tetapi tidak menyediakan fitur semantik awal. Transfer learning memanfaatkan filter pralatih sehingga model mencapai akurasi tinggi jauh lebih cepat pada data terbatas (Slide 14–15).

5.2 Trade-off performa vs stabilitas: B2 vs B3

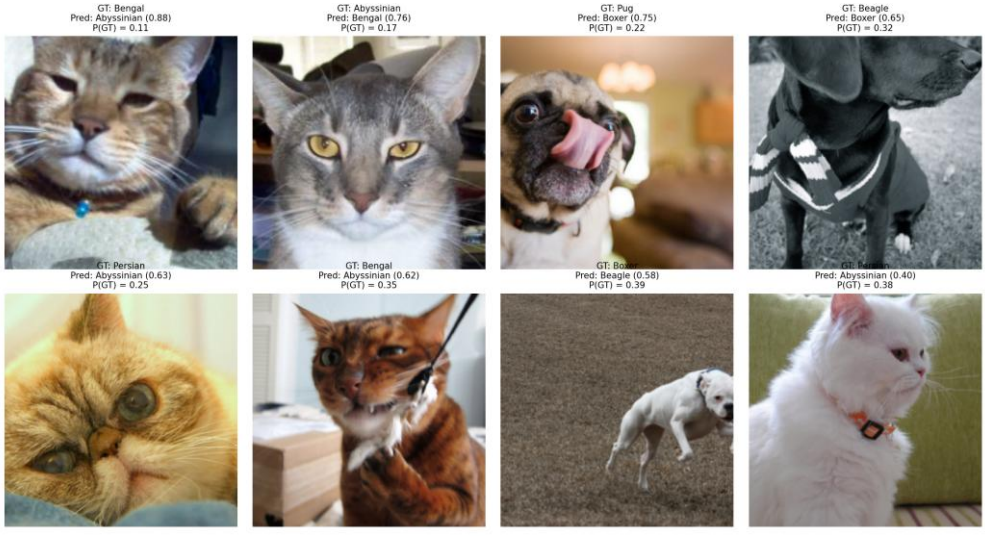
B2 menghasilkan validasi terbaik (0,9764) dan akurasi uji 0,9698, sedangkan B3 memperoleh validasi 0,9697 dan uji 0,9664. Perbedaan akurasi uji 0,0034 setara kira-kira satu citra dari 298, sehingga tidak cukup untuk menyimpulkan keunggulan umum hanya dari satu split dan satu seed. B2 mencapai epoch terbaik pada 13 dari 17 epoch, sedangkan B3 pada epoch 2 dari 6; hal ini konsisten dengan kepala klasifikasi yang belajar stabil saat backbone dibekukan, sementara fine-tuning memerlukan pemantauan lebih ketat karena bobot representasi ikut berubah. Untuk protokol ini, B2 adalah pilihan konservatif karena skor validasinya tertinggi dan hanya 5.130 parameter yang diperbarui; klaim B2 lebih baik tetap perlu uji multi-seed atau interval ketidakpastian (Slide 16, 28; Yosinski et al., 2014).

5.3 Peran augmentasi (B4) terhadap overfitting

Dengan augmentasi (B3), gap train−val pada epoch terbaik hanya 0,0072 dibanding 0,0262 tanpa augmentasi (B4), tetapi perbandingan ini tidak sepenuhnya sepadan: akurasi train B3 dihitung pada citra yang sedang diacak transformasinya, sehingga tugas train lebih sulit daripada validasi pada citra deterministik. Pada run ini B4 tanpa augmentasi justru meraih validasi 0,9731 dan test 0,9765, lebih tinggi daripada B3 (test 0,9664), namun selisih test hanya sekitar tiga citra dan tidak boleh menjadi satu-satunya dasar pemilihan. Artinya, augmentasi belum terbukti menguntungkan pada setup ini; keputusan perlu dikonfirmasi dengan seed tambahan, dan jika dipakai, pipeline data perlu dioptimalkan. Ini sejalan dengan prinsip bahwa augmentasi harus realistis dan meningkatkan keragaman tanpa mengaburkan label (Slide 20; Shorten & Khoshgoftaar, 2019).

6. Failure Analysis (C3)

Model terbaik dipilih berdasarkan validation accuracy, yaitu B2, agar test set tidak dipakai untuk pemilihan model. B2 salah pada 9 dari 298 citra uji; delapan kesalahan dengan confidence tertinggi ditampilkan pada Gambar 3 dan Tabel 3. Confusion matrix lengkap tersedia di repositori.



Gambar 3. Delapan misklasifikasi B2 dengan confidence tertinggi.

No	File	Ground truth	Prediksi	Conf.	P(GT)	Hipotesis penyebab
1	Bengal_143.jpg	Bengal	Abyssinian	0,88	0,11	Crop dekat menonjolkan bulu pendek dan garis wajah serupa.
2	Abyssinian_221.jpg	Abyssinian	Bengal	0,76	0,17	Warna/pola samar dan sudut frontal membuat kelas mirip.

No	File	Ground truth	Prediksi	Conf.	P(GT)	Hipotesis penyebab
3	pug_6.jpg	Pug	Boxer	0,76	0,22	Moncong pendek dan kepala lebar menyerupai ciri Boxer.
4	beagle_198.jpg	Beagle	Boxer	0,65	0,32	Foto monokrom dan crop menyamarkan ciri Beagle.
5	Persian_25.jpg	Persian	Abyssinian	0,63	0,25	Close-up hangat mengaburkan bentuk wajah dan tekstur bulu.
6	Bengal_84.jpg	Bengal	Abyssinian	0,62	0,35	Crop wajah membuat pola bulu pembeda kurang terlihat.
7	boxer_18.jpg	Boxer	Beagle	0,58	0,39	Pose bergerak dan jarak jauh menyamarkan proporsi kepala.
8	Persian_77.jpg	Persian	Abyssinian	0,40	0,38	Profil samping dan bulu putih menutupi ciri Persian.

Tabel 3. Kasus misklasifikasi; P(GT) = probabilitas model untuk label sebenarnya.

Confusion matrix tidak menunjukkan kesalahan lintas spesies: kesalahan kucing tetap diprediksi sebagai kucing, dan anjing sebagai anjing. Pasangan yang paling sering tertukar adalah Bengal–Abyssinian: dua citra Bengal diprediksi Abyssinian dan satu Abyssinian diprediksi Bengal. Keduanya kucing berbulu pendek dengan bentuk kepala dan pola garis wajah yang dapat terlihat mirip pada crop dekat atau pencahayaan tertentu. Persian juga dua kali diprediksi Abyssinian, terutama ketika close-up, sudut profil, atau pencahayaan menyamarkan ciri khas wajah dan bulu panjang. Pada anjing, Pug/Boxer dan Beagle/Boxer tertukar; moncong, bentuk kepala, pose, jarak, dan citra monokrom atau sebagian terpotong dapat menutupi ciri ras. Hipotesis visual ini bukan bukti kausal; pemeriksaan crop wajah, Grad-CAM, dan contoh tambahan diperlukan untuk menguji apakah model mengandalkan pola bulu, latar, atau bentuk kepala.

7. Rekomendasi dan Batasan (C4)

7.1 Rekomendasi rekayasa

Untuk protokol dan dataset saat ini, saya merekomendasikan B2 (feature extraction) sebagai baseline operasional: nilai validasinya tertinggi (0,9764), akurasi uji 0,9698 dengan macro-F1 0,9703, dan hanya 5.130 parameter yang dilatih. B4 tanpa augmentasi memberi skor uji tertinggi, tetapi validasinya di bawah B2; karena pemilihan model harus berdasar validasi, hasil test tersebut dipakai sebagai pelaporan, bukan untuk memilih konfigurasi. Operational constraints: gunakan B2 saat data terbatas, kelas serupa dengan ImageNet, dan anggaran pelatihan terbatas; pertahankan transformasi evaluasi deterministik dan pantau per-class recall. Bila data bertambah atau domain target jauh dari ImageNet, coba buka layer4/layer lebih dalam dengan LR kecil dan validasi multi-seed.

7.2 Batasan studi

Temuan studi terbatas oleh satu seed (42); pengulangan dengan seed yang sama memeriksa reproduksibilitas, bukan variasi antar-pembagian data. Dataset hanya mencakup 10 ras dan 298 citra uji, sehingga satu citra mengubah akurasi sekitar 0,34 poin persen; perbedaan B2–B3 kecil ini tidak kuat tanpa interval ketidakpastian. Trainval dan test resmi digabung sebelum split ulang, sehingga set uji yang dievaluasi bukan lagi test resmi yang terpisah. B1 juga berhenti dini (7 epoch) dan berakurasi train rendah, sehingga perbandingan from-scratch belum tentu setara dengan baseline yang dituning optimal. B5 (MobileNetV3-Small) dan evaluasi bonus/C5 tidak dijalankan, jadi tidak ada bukti untuk membandingkan efisiensi model ringan. Terakhir, augmentasi memberi overhead besar (7,3 vs 2,9 s/epoch) yang mengindikasikan bottleneck CPU/data pipeline.

Referensi

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. Proceedings of CVPR, 770–778.

Hidayaturrahman. (2026). Advanced CNNs and transfer learning [Bahan tayang Sesi 05]. BINUS University.

Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. Proceedings of ICML, 448–456.

Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., Kumaran, D., & Hadsell, R. (2017). Overcoming catastrophic forgetting in neural networks. PNAS, 114(13), 3521–3526.

Parkhi, O. M., Vedaldi, A., Zisserman, A., & Jawahar, C. V. (2012). Cats and dogs. Proceedings of CVPR, 3498–3505.

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. Journal of Big Data, 6, 60.

Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? Advances in NeurIPS 27, 3320–3328.

Lampiran — Pernyataan Penggunaan AI

Alat: Claude (Anthropic) dan ChatGPT (OpenAI).

Ruang lingkup: Claude (Anthropic) digunakan sesuai keterangan awal untuk membantu penyusunan pipeline eksperimen, peringkasan slide, pemeriksaan konsistensi log, README, dan kerangka laporan. ChatGPT (OpenAI) digunakan dalam penyusunan draf awal Bagian A1–A5, pembahasan komparatif (C2), ringkasan pola kesalahan (C3), rekomendasi dan batasan (C4), serta hipotesis visual pada Tabel 3 berdasarkan isi laporan yang tersedia. Masih perlu meninjau dan menyesuaikan seluruh isi dengan analisis sendiri, hasil eksperimen, serta aturan mata kuliah sebelum penyerahan.

Verifikasi eksperimental yang dicatat dalam laporan meliputi pencocokan jumlah trainable parameter B2 (5.130) dengan petunjuk tugas, pemeriksaan bahwa split train/val/test tidak beririsan, pengulangan notebook dengan metrik identik, serta pencocokan angka terhadap outputs/summary.csv. Masih perlu memastikan kembali bahwa seluruh langkah verifikasi tersebut benar-benar telah dilakukan dan bahwa pernyataan ini sesuai dengan proses kerja aktual.